Projekt zaliczeniowy PNA

Magdalena Latała 439869

2025-12-20

Abstract

Celem projektu było zbadanie, czy rozklad normalny oraz dwuskładnikowa mieszanka rozkładów normalnych są odpowiednie do modelowania zlogarytmowanych stóp zwrotu z akcji. Pobrano w tym celu dane o dziennych zwrotach z akcji 10 amerykańskich firm notowanych między 2015 a 2025 rokiem. Dopasowywano optymalne parametry ww. rozkładów przy użyciu metody największej wiarygodności oraz uogólnionej metody momentów. Estymacja parametrów mieszanki rozkładów poprzez GMM nie powiodła się. W testach statystycznych sprawdzono słuszość założeń typowych modeli rynków finansowych. Wyniki wskazują, że nie należy modelować stóp zwrotu z akcji przy pomocy rozkładu normalnego. Dwupunkowa mieszanka rozkładów normalnych nadaje się lepiej do tego celu, choć nie pozwala na modelowanie asymetrii występującej w empirycznym rozkładzie.

Wstęp

Analiza stóp zwrotu intrumentów finansowych to ciekawe zagadnienie, ponieważ zjawiska na giełdzie zależą od wielu czynników i nie dają się łatwo modelować. Moja osobista motywacja do podjęcia tego problemu wynika z tematów omawianych na mojej specjalizacji. Na jednych zajęciach wprowadzono popularny model Markowitza, w którym zakłada się normalność rozkładu zlogarytmowanych stóp zwrotu, podczas gdy na innych zajęciach omawialiśmy niedopasowanie rozkładu normalnego do takich zastosowań. Ta niejednoznaczność skłoniła mnie do zbadania tego zjawiska.

Dane

Dane do tego projektu pozyskane zostały przy użyciu paczki yfinance w Pythonie (https://pypi.org/project/yfinance/). Pobrano informacje o dziennych cenach akcji 10 dużych amerykańskich firm techologicznych (tickers: AAPL, AMD, AMZN, CRM, GOOGL, INTC, META, MSFT, NVDA, TSLA) z okresu od 2015-12-07 do 2025-12-05 (2515 dat). Następnie obliczono zwroty i zlogarywnowane zwroty dla każdej firmy. Ostateczny wektor danych poddawany analizie ustalono jako średnią ze zlogarytmowanych stóp zwrotu wszytkich firm (2514 wartości). Dodatkowo, do testów statystycznych, pobrano dane o dziennych wartościach indeksu giełdowego S&P500 dla takiego samego okresu. Obliczono średnią i odchylenie standardowe jego zlogarytmowanych zwrotów: $\sigma_{SP500} = 0.0115$, $\mu_{SP500} = 0.0005$. Kod wykorzystany do pobierania danych załączono do raportu.

Metody

Metoda największej wiarygodności

W metodzie największej wiarygodności (MLE) wyznaczono pierwsze i drugie pochodne logarytmu funkcji wiarygodności po parametrach rozkładu. Funkcja wiarygodności jest iloczynem wartości gęstości dla punktów odpowiadających danym, więc jej logarytm jest sumą logarytmów z gęstości w tych punktach. Ponieważ pochodna sumy to zawsze suma pochodnych, w poniższych wzorach przedstawiono jedynie pochodne jednego składkika takiej sumy, dla (przykładowego) punktu x. Wszystkie obliczenia przeprowadzono symbolicznie w programie Mathematica, kod załączono do raportu.

Funkcja log-wiarygodności rozkładu normalnego dana jest wzorem:

$$L(\mu, \sigma; x) = -\log\left(\sqrt{2\pi}\sigma\right) - \frac{(x-\mu)^2}{2\sigma^2}\,.$$

Jej gradient ma wzór:

$$\nabla L(\mu, \sigma; x) = \left[\frac{x-\mu}{\sigma^2}, \quad \frac{(x-\mu)^2}{\sigma^3} - \frac{1}{\sigma}\right],$$

a Hessian wyraża się przez:

$$H_L = \begin{bmatrix} -\frac{1}{\sigma^2}, & -\frac{2(x-\mu)}{\sigma^3} \\ -\frac{2(x-\mu)}{\sigma^3}, & \frac{1}{\sigma^2} - \frac{3(x-\mu)^2}{\sigma^4} \end{bmatrix}.$$

Funkcje gęstości prawdopodobieństwa i log-wiarygoności dla dwupunkowej mieszanki rozkładów normalnych o średnich równych zero i odchyleniach σ oraz β dane są wzorami:

$$f(x) = \frac{(1-p)e^{-\frac{x^2}{2\beta^2}}}{\sqrt{2\pi}\beta} + \frac{pe^{-\frac{x^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} \quad ; \qquad L(\sigma, \beta, p\,;\, x) = \log\left(\frac{(1-p)e^{-\frac{x^2}{2\beta^2}}}{\sqrt{2\pi}\beta} + \frac{pe^{-\frac{x^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}\right),$$

gdzie p można interpretować jako prawdopodobieństwo, że rynek znajduje się w stanie cechującym się odchyleniem σ.

Gradient funkcji L wynosi:

$$\nabla L(\sigma, \beta, p\,;\, x) = \begin{bmatrix} \frac{\frac{px^2e^{-\frac{x^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma^4} - \frac{pe^{-\frac{x^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma^2}}{\frac{(1-p)e^{-\frac{x^2}{2\beta^2}}}{\sqrt{2\pi}\beta} + \frac{pe^{-\frac{x^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}}, & \frac{\frac{(1-p)x^2e^{-\frac{x^2}{2\beta^2}}}{\sqrt{2\pi}\beta^4} - \frac{(1-p)e^{-\frac{x^2}{2\beta^2}}}{\sqrt{2\pi}\beta^2}}{\frac{(1-p)e^{-\frac{x^2}{2\beta^2}}}{\sqrt{2\pi}\beta} + \frac{pe^{-\frac{x^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}}, & \frac{\frac{e^{-\frac{x^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma} - \frac{e^{-\frac{x^2}{2\beta^2}}}{\sqrt{2\pi}\beta}}{\frac{(1-p)e^{-\frac{x^2}{2\beta^2}}}{\sqrt{2\pi}\beta} + \frac{pe^{-\frac{x^2}{2\sigma^2}}}{\sqrt{2\pi}\sigma}} \end{bmatrix}$$

Hessian został obliczony symbolicznie i jest zawarty w załączniku do raportu. Ze względu na jego skomplikowanie nie został uwzględniony w obliczeniach MLE. Po wstępnych testach ustalono, że gradient wystarcza, aby funckja optymalizująca znalazła maksimum.

Uogólniona metoda momentów

W celu przeprowadzenia estymacji parametrów uogólnioną metodą momentów (GMM) wyznaczono momenty badanych rozkładów. Dla rozkładu normalnego wynoszą one:

$$\mathbb{E}X = \mu, \qquad \mathbb{E}X^3 = \mu^3 + 3\mu\sigma^2, \qquad \mathbb{E}X^2 = \mu^2 + \sigma^2$$

Momenty dwupunktowej mieszanki gaussowskiej to:

$$\mathbb{E}X^2 = (1-p)\beta^2 + p\sigma^2, \qquad \mathbb{E}X^4 = 3(1-p)\beta^4 + 3p\sigma^4, \qquad \mathbb{E}X^6 = 15(1-p)\beta^2 + 15p\sigma^2, \qquad \mathbb{E}X^8 = 105(1-p)\beta^2 + 105p\sigma^2$$

Funkcje zastosowane w implementacji GMM oraz MLE zamieszono w aneksie z kodem.

Testy statystyczne

Dla każdego rozkładu i dla każdej metody testowano 2 hipotezy zerowe - pierwszą dotyczącą dwóch parametrów jednocześnie, a drugą - dotyczącą jednego parametru (łącznie 8 testów). Dla rozkładu normalnego testowano hipotezy odpowiadające typowym założeniom w modelach finansowych:

- H_0^z: $\mu = \mu_{SP500}$, $\sigma = \sigma_{SP500}$;
- H_0^p: $\mu = 0$.

Dla mieszanki rozkładów testowano, czy można założyć równość wyestymowanych odchyleń (a więc czy model dwóch różnych odchyleń jest uzasadniony) oraz czy udział rozkładu o wyższej wariancji istotnie różni się od zera:

- H_0^z: $\sigma = \beta = \sigma_{SP500}$;
- H_0^p: $p = 0$.

Do testowania hipotez prostych użyto testu Z, natomiast do testowania hipotez złożonych wykorzystano test Walda (GMM) oraz test ilorazu wiarygodności LR (MLE). Błędy estymacji parametrów wyznaczono z Hessianu: $\Sigma = -H^{-1}$ dla MLE oraz z Jakobianu D i macierzy kowariancji S: $(S'D^{-1}S)^{-1}$ dla GMM[1].

Wyniki

Estymacja parametrów rozkładów

Poniższe tabele zawierają wyniki dopasowań parametrów metodą MLE i GMM dla obydwu rozkładów.

Table 1: Wyniki estymacji parametrów rozkładu normalnego

Metoda	μ	σ	SE(μ)	SE(σ)
MLE	0.0010	0.0183	4e-04	3e-04
GMM	0.0011	0.0173	4e-04	3e-04

Table 2: Wyniki estymacji parametrów mieszanki rozkładów normalnych

Metoda	σ	β	p	SE(σ)	SE(β)	SE(p)
MLE	0.0291	0.0117	0.2782	0.0017	6e-04	0.047

W przypadku rozkładu normalnego obie metody dały podobne wyniki estymacji i błędów. W przypadku mieszanki rozkładów jedynie MLE dała miarodajne wyniki. Metoda GMM zawiodła ze względu na konieczność odwracania macierzy, która była osobliwa (prawdopodobnie ze względu na małe wielkości elementów - ułamkowych zwrotów podniesionych do wysokich potęg).

Testy statystyczne

Table 3: Wyniki testów statystycznych

Rozkład	metoda	H_0	p value	wynik (dla $\alpha = 0.01$)
Normalny	MLE	$\mu = \mu_{SP500}$ i $\sigma = \sigma_{SP500}$	0	H_0 odrzucona
Normalny	MLE	$\mu = 0$	0.005	H_0 odrzucona
Normalny	GMM	$\mu = \mu_{SP500}$ i $\sigma = \sigma_{SP500}$	4e-65	H_0 odrzucona
Normalny	GMM	$\mu = 0$	0.003	H_0 odrzucona
Mieszanka	MLE	$\sigma = \beta = \sigma_{SP500}$	0	H_0 odrzucona
Mieszanka	MLE	$p = 0$	3e-09	H_0 odrzucona

Ze względu na niepowodzenie estymacji parametrów mieszanki rozkładów metodą GMM, nie ma dla niej wyników w tej sekcji. Kod, który odpowiadał tej częsci analizy, pozostawiono w aneksie. Niewykonane linie zostały opatrzone komentarzami.

[1] https://en.wikipedia.org/wiki/Generalized_method_of_moments#Relative_Efficiency, równanie 2

Wnioski

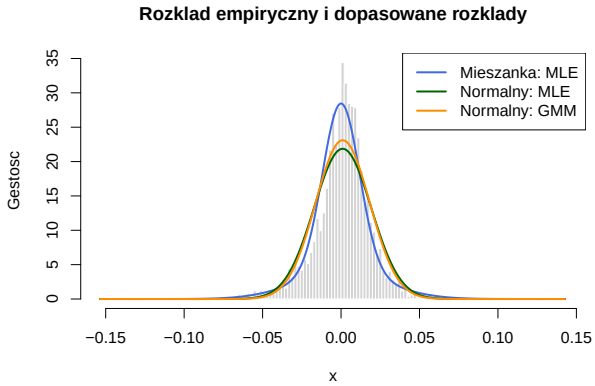

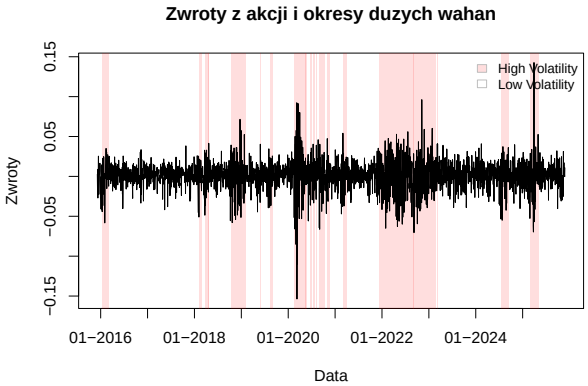

Lewy wykres obrazuje ostateczne wyniki dopasowywania rozkładów. Widać wyraźnie, że rozkład normalny nie jest odpowiednim wyborem przy modelowaniu zwrotów z akcji. Kształt wyestymowanej mieszanki rozkładów znacznie lepiej dopasowuje się do danych.

Wyniki testów statystycznych wskazują, że podejścia typowe w prostych modelach rynków finansowych nie znajdują potwierdzenia w danych. Rozkład normalny nie jest dobrym wyborem dla tego problemu. Potwierdzono natomiast słuszność wyboru do tego celu mieszanki dwupuntkowej. Parametr p okazał się istotny, co wskazuje, że występowanie na ryznku wzmożonej zmienności nie jest pomijalne. Taki sam wniosek płynie z odrzucenia hipotezy o równości odchyleń w mieszance rozkładów.

Wybór mieszkanki rozkładów normalnych ma również dodatkowy sens ze względu na interpretację parametru p jako prawdopodobieństwa, że gospodarka jest w stanie recesji, w którym to na rynkach akcji występują większe wahania (a więc większe odchylenia stóp zwrotu). Prawy wykres obrazuje, jakie okresy czasu zakwalifikowane zostałyby jako recesja, gdyby przyjąć $p = 0.28$, czyli takie, jak w wynikach modelu [2] Widać, że taki model dobrze oddaje historyczne wydarzenia, takie jak np wybuch pandemii.

Potencjalny kierunek dalszych badań jasno wynika z rezultatów przedstawionych na prawym wykresie. Wyraźnie widać, że choć dopasowanie dwupunktowej mieszanki jest znacznie lepsze niż rozkładu normalnego, to wciąż nie jest to najlepszy wybór, gdyż dane są wyraźnie asymetryczne. O asymetrii świadczy również odrzucenie hipotezy o zerowej średniej zwrotów. Należy więc zbadać inne mieszanki, które dopuszczają asymetrię (np. mieszanka dwupunktowa z niezerowymi średnimi lub mieszanki ciągłe).

Bibliografia

1. Morkūnaitė, I., Celov, D. and Leipus, R. (2024) 'Evaluation of Value-at-Risk (VaR) using the Gaussian Mixture Models', Research in Statistics, 2(1). doi: 10.1080/27684520.2024.2346075.
2. Scrucca, L. (2024). Entropy-Based Volatility Analysis of Financial Log-Returns Using Gaussian Mixture Models. Entropy, 26(11), 907. https://doi.org/10.3390/e26110907

[2] Obliczono kroczącą wariancję zwrotów z akcji dla okna 30 dni. Na wykresie zanaczono okresy, kiedy wariancja ta była większa niż w 72% przypadków.

Kod

```r
data = read.csv('stock_data.csv')

n_stocks = length(data) - 1

N = length(data$Date)

returns <- data[-1,]
returns[, -1] <- data[-1, -1] / data[-nrow(data), -1] - 1

log_returns <- data[-1,]
log_returns[, -1] <- log(data[-1, -1] / data[-nrow(data), -1])

x = apply(log_returns[2:ncol(log_returns)], 1, mean)

results_normal = data.frame(
  method = character(),
  mu = numeric(),
  sigma = numeric(),
  SE_mu = numeric(),
  SE_sigma = numeric(),
  stringsAsFactors = FALSE
)

results_mixture = data.frame(
  method = character(),
  sigma = numeric(),
  beta = numeric(),
  p = numeric(),
  SE_sigma = numeric(),
  SE_beta = numeric(),
  SE_p = numeric(),
  stringsAsFactors = FALSE
)

sd_sp = 0.0115
mu_sp = 0.0005
```

```r
# metoda MLE dla rozkłądu normalnego

loglik = function(params){
  sigma = params[2]
  mu = params[1]
  n = length(x)
  return(-n/2*log(2*pi)-n*log(sigma)-1/2/sigma/sigma*sum((x-mu)^2))
}


grad = function(params){
  mu = params[1]
  sigma = params[2]
  n = length(x)

  d_mu = sum(x - mu) / sigma^2
  d_sigma = -n / sigma + sum((x - mu)^2) / sigma^3

  c(d_mu, d_sigma)
}

hess = function(params){
  mu = params[1]
  sigma = params[2]
  n = length(x)

  h11 = -n / sigma^2
  h12 = -2 * sum(x - mu) / sigma^3
  h22 = n / sigma^2 - 3 * sum((x - mu)^2) / sigma^4

  matrix(c(h11, h12,
           h12, h22), nrow = 2)
}

wynik = maxNR(
  loglik,
  grad   = grad,
  hess   = hess,
  start  = c(mean(x), sd(x))
)

summary(wynik)
```

```
## --------------------------------------------
## Newton-Raphson maximisation
## Number of iterations: 2
## Return code: 1
## gradient close to zero (gradtol)
## Function value: 6497.743
## Estimates:
##         estimate     gradient
## [1,] 0.001012883 7.649405e-14
## [2,] 0.018250520 6.752089e-09
## --------------------------------------------
```

```r
SE_vector = sqrt(diag(solve(-wynik$hessian)))

results_normal[1, ] = list(
  "MLE",
  wynik$estimate[1], wynik$estimate[2],
  SE_vector[1], SE_vector[2]
)


# test mu = mu_sp i sigma= sd_sp

mu_0 = mu_sp
sigma_0 = sd_sp

lnL_unrestricted = wynik$maximum

lnL_restricted = loglik(c(mu_0, sigma_0))

LR = 2*(lnL_unrestricted - lnL_restricted)
g = 2
alpha=0.05

qchisq(1-alpha, g)
```

```
## [1] 5.991465
```

```r
p_value = 1-pchisq(LR, g)
p_value
```

```
## [1] 0
```

```r
(p_value)
```

```
## [1] 0
```

```r
# test mu = 0

mu_0 = 0
Z = (wynik$estimate[1]-mu_0)/SE_vector[1]
p_value = 2 * pnorm(-abs(Z))

(p_value)
```

```
## [1] 0.005390819
```

```r
# MLE dla mieszanki rozkładów normalnych

loglik = function(params){
  sigma = params[1]
  beta  = params[2]
  p     = params[3]

  if(sigma <= 0 | beta <= 0 | p < 0 | p > 1) return(NA)

  return(sum(log(p/sqrt(2*pi)/sigma*exp(-x^2/2/sigma^2) + (1-p)/sqrt(2*pi)/beta*exp(-x^2/2/beta^2))))
}


grad = function(params){
  sigma = params[1]
  beta  = params[2]
  p     = params[3]

  num_sigma =
    (p * x^2 * exp(-x^2 / (2 * sigma^2))) / (sqrt(2*pi) * sigma^4) -
    (p * exp(-x^2 / (2 * sigma^2))) / (sqrt(2*pi) * sigma^2)

  num_beta =
    ((1 - p) * x^2 * exp(-x^2 / (2 * beta^2))) / (sqrt(2*pi) * beta^4) -
    ((1 - p) * exp(-x^2 / (2 * beta^2))) / (sqrt(2*pi) * beta^2)

  num_p =
    exp(-x^2 / (2 * sigma^2)) / (sqrt(2*pi) * sigma) -
    exp(-x^2 / (2 * beta^2)) / (sqrt(2*pi) * beta)

  denom =
    ((1 - p) * exp(-x^2 / (2 * beta^2))) / (sqrt(2*pi) * beta) +
    (p * exp(-x^2 / (2 * sigma^2))) / (sqrt(2*pi) * sigma)

  d_sigma = sum(num_sigma / denom)
  d_beta  = sum(num_beta / denom)
  d_p     = sum(num_p / denom)

  return(c(d_sigma, d_beta, d_p))
}


wynik = maxNR(
  loglik,
  grad = grad,
  start  = c(sd(x), sd(x) , 0.9)
)

summary(wynik)
```

```
## --------------------------------------------
## Newton-Raphson maximisation
## Number of iterations: 10
## Return code: 1
```

```
## gradient close to zero (gradtol)
## Function value: 6654.796
## Estimates:
##        estimate     gradient
## [1,] 0.02909403 6.333074e-07
## [2,] 0.01168881 6.615998e-07
## [3,] 0.27820442 2.900257e-08
## ---------------------------------------------
```

```
SE_vector = sqrt(diag(solve(-wynik$hessian)))

results_mixture[1, ] = list(
  "MLE",
  wynik$estimate[1], wynik$estimate[2],wynik$estimate[3],
  SE_vector[1], SE_vector[2], SE_vector[3]
)

# test sigma = beta = sqrt(p*sigma^2 + (1-p)*beta^2)

sigma_0 = sd_sp
beta_0 = sd_sp

lnL_unrestricted = wynik$maximum

lnL_restricted = loglik(c(sigma_0, beta_0, wynik$estimate[3]))

LR = 2*(lnL_unrestricted - lnL_restricted)
g = 2
alpha=0.05

qchisq(1-alpha, g)
```

```
## [1] 5.991465
```

```
p_value = 1-pchisq(LR, g)

(p_value)
```

```
## [1] 0
```

```
# test p=0

p_0 = 0
Z = (wynik$estimate[3]-p_0)/SE_vector[3]
p_value = 2 * pnorm(-abs(Z))

(p_value)
```

```
## [1] 3.328347e-09
```

```r
# GMM dla rozkładu normalnego

Qmin = function(params) {
  mu = params[1]
  sigma=params[2]

  m1 = x-mu
  m2 = (x-mu)^2 - sigma^2
  m3 = (x-mu)^4 - 3* sigma^4

  m = rbind(m1, m2, m3)

  MT = apply(m, 1, mean)

  g_centered = m - MT
  S_hat = g_centered %*% t(g_centered) / length(x)

  val =  -0.5 * t(MT) %*% solve(S_hat) %*% MT
  return(val)
}


wynik = maxNR(fn=Qmin, start=c(mean(x), sd(x)))
summary(wynik)
```

```
## --------------------------------------------
## Newton-Raphson maximisation
## Number of iterations: 3
## Return code: 1
## gradient close to zero (gradtol)
## Function value: -0.001188141
## Estimates:
##         estimate      gradient
## [1,] 0.001065253 -7.913592e-09
## [2,] 0.017268074 -1.502442e-07
## --------------------------------------------
```

```r
m1 = x-wynik$estimate[1]
m2 = (x-wynik$estimate[1])^2 - wynik$estimate[2]^2
m3 = (x-wynik$estimate[1])^4 - 3* wynik$estimate[2]^4
m = rbind(m1, m2, m3)
MT = apply(m, 1, mean)
g_centered = m - MT
S = g_centered %*% t(g_centered) / length(x)

D = matrix(0, nrow = 3, ncol = 2)
D[1, ] = c(-1, 0)
D[2, ] = c(-2 * mean(x - wynik$estimate[1]), -2 * wynik$estimate[2])
D[3, ] = c(-4 * mean((x - wynik$estimate[1])^3), -12 * wynik$estimate[2]^3)

V = solve(t(D) %*% solve(S) %*% D) / length(x)
SE_vector = sqrt(diag(V))

results_normal[2, ] = list(
```

```r
  "GMM",
  wynik$estimate[1], wynik$estimate[2],
  SE_vector[1], SE_vector[2]
)


# test mu = 0

mu_0=0
Z = (wynik$estimate[1]-mu_0)/SE_vector[1]
p_value = 2*pnorm(-abs(Z))

cat("p_value:")
```

```
## p_value:
```

```r
(p_value)
```

```
## [1] 0.003385112
```

```r
# test mu=mu_sp i sigma=sd_sp

R = matrix(c(1, 0, 0, 1), nrow = 2)
q = c(mu_sp, sd_sp)
g = 2
k = 2

Wald.stat = function(R, q, theta=wynik$estimate, sigma = V){
  rtq = R%*%theta - q
  rsr = solve(R%*%sigma%*%t(R))
  return(t(rtq) %*% rsr %*% rtq)
}

W = Wald.stat(R, q)
critical.value = qchisq(0.95, g)
# Z<wart.kryt, nie ma podstaw do odrzucenia hipotezy

(p_value = pchisq(abs(W), g, lower.tail = FALSE))
```

```
##              [,1]
## [1,] 3.959805e-65
```

```r
# GMM dla mieszanki

Qmin = function(params) {
  sigma = params[1]
  beta  = params[2]
  p     = params[3]

  m1 = x
  m2 = x^2 - p * sigma^2 - (1 - p) * beta^2
  m3 = x^3
  m4 = x^4 - 3 * (p * sigma^4 + (1 - p) * beta^4)
  m6 = x^6 - 15 * (p * sigma^6 + (1 - p) * beta^6)
  m8 = x^8 - 105 * (p * sigma^8 + (1 - p) * beta^8)

  #m = rbind(m1, m2, m3, m4)
  m = rbind(m2, m4, m6, m8)

  MT = apply(m, 1, mean)

  g_centered = m - MT
  #S_hat = (g_centered) %*% t(g_centered) / length(x)

  S_hat = diag(nrow=4) # to daje jakiś wynik optymalizacji

  val = -0.5 * t(MT) %*% solve(S_hat) %*% MT
  return(val)
}

wynik = maxNR(fn=Qmin, start=c(0.02867873, 0.01238308, 0.27785764)) # dla właściwej S_hat nie daje sie
summary(wynik)
```

```
## --------------------------------------------
## Newton-Raphson maximisation
## Number of iterations: 1
## Return code: 1
## gradient close to zero (gradtol)
## Function value: -7.27681e-14
## Estimates:
##        estimate      gradient
## [1,] 0.02847695 -1.089419e-09
## [2,] 0.01227701 -1.246916e-09
## [3,] 0.27787001 -4.593796e-11
## --------------------------------------------
```

```r
# wynik dla jednostkowej macierzy wag solve(S)

m1 = x
m2 = x^2 - wynik$estimate[3] * wynik$estimate[1]^2 -(1 - wynik$estimate[3]) * wynik$estimate[2]^2
m3 = x^3
m4 = x^4 - 3 * (wynik$estimate[3] * wynik$estimate[1]^4 + (1 - wynik$estimate[3]) * wynik$estimate[2]^4
m = rbind(m1, m2, m3, m4)
MT = apply(m, 1, mean)
g_centered = m - MT
S = g_centered %*% t(g_centered) / length(x)
```

```r
D = matrix(0, nrow = 4, ncol = 3)
D[2, ] = c(
  -2 * wynik$estimate[3] * wynik$estimate[1],
  -2 * (1 - wynik$estimate[3]) * wynik$estimate[2],
  -(wynik$estimate[1]^2 - wynik$estimate[2]^2)
)
D[4, ] = c(
  -12 * wynik$estimate[3] * wynik$estimate[1]^3,
  -12 * (1 - wynik$estimate[3]) * wynik$estimate[2]^3,
  -3 * (wynik$estimate[1]^4 - wynik$estimate[2]^4)
)

# V = solve(t(D) %*% solve(S) %*% D) / length(x)  # S nie daje się odwrócić (singularity)
V = 1e10*diag(nrow=3)
SE_vector = sqrt(diag(V))

results_mixture[2, ] = list(
  "GMM",
  wynik$estimate[1], wynik$estimate[2],wynik$estimate[3],
  SE_vector[1], SE_vector[2], SE_vector[3]
)


# test p= 0

p_0=0
Z = (wynik$estimate[3]-p_0)/SE_vector[3]
p_val = 2 * pnorm(-abs(Z))


# test sigma=beta (=sd_sp)

R = matrix(c(1, -1, 0), nrow = 1, byrow = TRUE)
q = c(0)

g = nrow(R)

Wald.stat = function(R, q, theta=wynik$estimate, sigma = V){
  rtq = R%*%theta - q
  rsr = solve(R%*%sigma  %*%t(R))

  return(t(rtq) %*% rsr %*% rtq)
}

W = Wald.stat(R, q)
critical.value = qchisq(0.95, g)

(p_value = pchisq(abs(W), g, lower.tail = FALSE))
```

```
##           [,1]
## [1,] 0.9999999
```